

The Universality of Electricity Demand

Zero-Shot Foundation Models Match Locally-Trained Accuracy on Brazil's Power Grid

Nelson Barlow

Centro de Informática — UFPE

Olá. Meu projeto investiga uma pergunta simples mas com grande impacto prático: será que modelos de fundação de séries temporais conseguem prever a demanda de energia do Brasil SEM nunca terem sido treinados em dados brasileiros? Eu chamo essa hipótese de "universalidade da demanda elétrica".
[20s]

O problema: previsão de carga exige dados locais

- Previsão de carga de curto prazo (STLF) sustenta despacho, reservas e o mercado day-ahead.
- Paradigma dominante: **cada concessionária treina seu próprio modelo** com anos de histórico local + clima + calendário.
- Barreira pesada em redes com poucos dados: regiões recém-interligadas, microrredes, países em desenvolvimento.

Hoje, prever carga elétrica significa que cada operador constrói um modelo sob medida, treinado em anos de dados locais. Isso funciona, mas é caro e impossível onde não há histórico: uma microrrede nova, uma região recém-conectada. A pergunta é: dá pra pular essa etapa? [30s]

A hipótese: universalidade da demanda

Forças universais

(transferem entre redes)

- Física de aquecimento/refrigeração
- Ritmo circadiano (pico diurno, vale noturno)
- Ciclo semanal trabalho/descanso

Forças locais

(NÃO transferem)

- Feriados nacionais
- Restrições hidrológicas
- Sazonalidade do hemisfério sul

Se um modelo pré-treinado internalizou a parte universal, ele transfere zero-shot e o erro residual fica confinado à parte local.

A intuição: a demanda elétrica tem duas camadas. Uma universal — física e comportamento humano, que produz o mesmo formato de curva em qualquer lugar do mundo. E uma local — feriados, hidrologia, estação invertida. Minha hipótese é que um modelo treinado em séries globais já aprendeu a camada universal. Então ele deveria acertar zero-shot, e errar só na parte local. Vou testar exatamente isso.

[40s]

Dados

- ONS (dados.ons.org.br), CC-BY 4.0
- Horário, 2019–2025, 61.368 linhas
- 4 subsistemas do SIN (SE $\approx$ 55%)
- Réplica: TEPCO (Tóquio)
- Teste: últimos 365 dias; zero-shot só vê o contexto

Modelos

- **Zero-shot:** Chronos-2 (120M), Moirai 2.0 (11M), TiRex (35M)
- **Treinados:** N-BEATS (ajustado), Linear, LSTM
- Baseline: Naive (7 dias atrás)

Sem vazamento: ONS ausente do corpus do Chronos.

Uso dados horários da ONS, sete anos, os quatro subsistemas do sistema interligado. Comparo três modelos de fundação zero-shot — Chronos-2, Moirai e TiRex — contra um N-BEATS ajustado e treinado em cinco anos de dados locais, mais baselines. Importante: verifiquei que os dados da ONS NÃO estão no corpus de treino do Chronos — não há vazamento. Os zero-shot só enxergam a janela de contexto. [35s]

Resultado principal — SE, horizonte 24h

Modelo	Tipo	MAPE
Chronos-2 (fine-tuned)	Fine-tuned	1,73%
Chronos-2	Zero-shot	1,86%
Moirai 2.0	Zero-shot	1,93%
N-BEATS (ajustado)	Treinado 5+ anos	1,91% $\pm$ 0,08%
TiRex	Zero-shot	2,33%
Naive (7 dias)	Baseline	5,13%

Zero-shot Chronos-2 (1,86%) iguala um N-BEATS treinado em 5 anos (1,91%) — sem treino local.

Este é o resultado central. No subsistema Sudeste, horizonte de 24 horas: o Chronos-2 zero-shot atinge 1,86% de MAPE. O N-BEATS, treinado em cinco anos de dados locais, fica em 1,91%. Ou seja, o modelo que NUNCA viu dados brasileiros empata com — na verdade, levemente supera — o modelo treinado localmente. Todos os modelos de fundação batem o baseline naive de 5,13% com folga. Fine-tuning leve ganha só mais 7%. [50s]

É um empate estatístico, não sorte

- Teste de **Diebold–Mariano** contra as 3 sementes do N-BEATS: $p > 0,29$ (sem diferença significativa).
- Intervalos de confiança 95% por bootstrap se sobrepõem (Chronos-2: [1,70%, 2,04%]).
- N-BEATS foi devidamente ajustado: grid search (input length $\times$ lr), 3 sementes $\rightarrow 1,91\% \pm 0,08\%$.

Mesma acurácia. **Um precisa de 5 anos de treino; o outro, de zero.**

Alguém poderia dizer: 1,86 contra 1,91, é ruído. Exatamente — e é esse o ponto. O teste de Diebold-Mariano dá p maior que 0,29, então a diferença NÃO é estatisticamente significativa. Os intervalos de confiança se sobrepõem. E garanti que o N-BEATS estava bem ajustado, com busca em grade e três sementes. A conclusão honesta é: mesma acurácia. A diferença é que um exigiu cinco anos de treino local e o outro, nenhum. [30s]

Generaliza em todas as dimensões

- **4 subsistemas:** Chronos-2 lidera todos (1,67–3,17%), $R^2 > 0,90$.
- **3 anos de teste:** estável, $1,89\% \pm 0,04\%$.
- **Contexto:** limiar de 1 semana; MAPE cai pela metade ao ver um ciclo semanal completo. 30 dias = ótimo.
- **Horizonte:** melhor em 24–168h; naive vence só após ~ 2 semanas.
- **Escala:** família Bolt escala log-linear (Tiny 2,28% $\rightarrow$ Chronos-2 1,86%).
- **Probabilístico:** bem calibrado; Chronos-2 melhor CRPS, Moirai intervalos mais nítidos.

O resultado não é um acaso do Sudeste. Ele se mantém nos quatro subsistemas, com R-quadrado acima de 0,90 em todos. Mantém-se em três anos diferentes de teste. Sobre contexto: o modelo precisa de pelo menos uma semana de histórico — quando vê um ciclo semanal completo, o erro cai pela metade; 30 dias é o ponto ideal. Em horizonte, os modelos de fundação ganham até duas semanas; depois disso, o naive volta a vencer. Use para operação de curto prazo. [45s]

Réplica entre países: Tóquio (TEPCO)

Modelo	Tipo	MAPE
Chronos-2	Zero-shot	3,91%
Moirai 2.0	Zero-shot	3,94%
TiRex	Zero-shot	4,05%
N-BEATS	Treinado 5 anos	4,44%
Naive (7 dias)	Baseline	8,86%

Outro país, **outro hemisfério, outro calendário** — mesmo ranking.
Os três zero-shot **vencem** o N-BEATS treinado localmente.

A evidência mais forte da universalidade: repeti tudo na rede de Tóquio, a TEPCO. País diferente, hemisfério diferente, calendário de feriados diferente. E o mesmo padrão aparece: os três modelos zero-shot batem o N-BEATS treinado em cinco anos de dados japoneses. O MAPE absoluto é maior porque a demanda japonesa é mais volátil, mas o resultado qualitativo se sustenta entre países. Isso é difícil de explicar a não ser que exista mesmo uma estrutura universal na demanda. [40s]

Onde falha: feriados

- Em feriados nacionais brasileiros, o Chronos-2 degrada para **4–5×** o erro de dia normal.
- Motivo: nada no corpus global sinaliza um feriado brasileiro → ele prevê demanda de dia útil.
- É propriedade **dos dados, não de um modelo**: Moirai 7,9%, TiRex 9,1%, naive 12,8% nos mesmos feriados (vs. $\sim 1,6\%$ normal).

Exatamente o previsto: **a fronteira da universalidade é o calendário local.**

E onde o modelo falha? Exatamente onde a hipótese previu: feriados. Em feriados nacionais, o erro do Chronos-2 sobe de cerca de 1,6% para quatro ou cinco vezes isso. A razão é intuitiva — nada no corpus global de treino diz a ele que é feriado no Brasil, então ele prevê um dia útil comum. E não é defeito de um modelo só: todos degradam igual, inclusive o naive. Isso confirma a fronteira: o que não transfere é o conhecimento de calendário local. [40s]

A correção funciona: 1 covariável de feriado

Regime	Zero-shot	+ Covariável	Δ
Feriado	6,76%	4,37%	−35%
Carnaval	5,68%	4,64%	−18%
Dia seguinte	2,29%	1,93%	−16%
Dia normal	1,53%	1,53%	0%
Geral	1,82%	1,73%	−5%

Uma covariável binária de feriado + fine-tuning leve **recupera 35% do erro de feriado**, sem tocar nos dias normais.

E se a falha é falta de conhecimento de calendário, basta fornecer esse conhecimento. Adicionei UMA covariável binária de feriado, com fine-tuning leve. O erro de feriado cai 35%, o Carnaval 18%, o dia seguinte ao feriado 16% — e os dias normais ficam intactos. Isso fecha o argumento: a fronteira da universalidade é conhecimento de calendário, não uma limitação de arquitetura. Forneça o pedaço local que falta, e o modelo recupera quase toda a diferença. [35s]

Conclusão e receita operacional

Universalidade limitada da demanda elétrica

Estrutura física e comportamental transfere zero-shot entre redes, anos e países; só o calendário local não transfere — e uma covariável o recupera.

Receita para redes com poucos dados:

- ① Comece zero-shot (Chronos-2, ou Moirai 11M se houver restrição) com ~ 30 dias de contexto.
- ② Fine-tune se possível ($\sim 7\%$ de ganho, 40 min em CPU).
- ③ Adicione covariável binária de feriado.
- ④ Não use além de ~ 2 semanas de horizonte.

Código e dados: github.com/nelsonbarlow/brazil-energy-forecast

Em resumo: a demanda elétrica tem uma universalidade, mas com fronteira precisa. A estrutura física e comportamental transfere entre redes, anos e até países. Só o calendário local não transfere — e uma única covariável o recupera. Para um operador com poucos dados, a receita prática é: comece zero-shot com 30 dias de contexto, faça fine-tuning se puder, adicione a covariável de feriado, e não passe de duas semanas de horizonte. Previsão day-ahead precisa não exige mais anos de desenvolvimento local. Obrigado. Todo o código está no GitHub. [35s]